

Rapport de stage 3A

Mathieu Thomassin

2024-08-31

[Download PDF](#)

Table des matières

- [Introduction](#)
- Découverte et Contexte
- Recherche et Collecte de Données
- Choix des Problèmes et des Outils de Machine Learning
- Exploration de Modèles et Outils Avancés
- Anomaly Detection et Modèles de Classification
- Exploration d'Articles Scientifiques
- Modélisation et Évaluation des Modèles
- Travail avec Splunk et Pipelines
- Expérimentations et Déploiement
- Reproductibilité et MLOps
- [Conclusion](#)
- [Annexe](#)

Introduction

Contexte général du stage

Importance de la cybersécurité et du machine learning dans ce domaine

Objectifs du stage

1. Découverte et Contexte

Premiers pas dans le stage : Enthousiasme et incertitude

Introduction à la cybersécurité : Définition et importance

Présentation de l'équipe SOC et du système d'information (SI)

Compréhension du SIEM et des logs

2. Recherche et Collecte de Données

Attente de Splunk et recherche de datasets pertinents

- Types de données : Réseau, logs, HTTP
- Sélection et préparation des datasets

Présentation des premières données obtenues

3. Choix des Problèmes et des Outils de Machine Learning

Définition des problèmes de machine learning en cybersécurité

Introduction à Scikit-learn et choix des modèles

Formation à l'interprétabilité des modèles

4. Exploration de Modèles et Outils Avancés

Essais avec XGBoost pour la classification des malwares

Découverte de MLflow et utilisation de l'API

Introduction au deep learning avec le livre "Deep Learning from Scratch" (DLFS)

Exploration des design patterns en deep learning

5. Anomaly Detection et Modèles de Classification

Détour par la détection d'anomalies : Difficultés et recentrage

Analyses simples avec KNN et clustering

Analyse des données HTTP et détection des attaques (ex. DDOS)

Focalisation sur l'analyse des URL et compréhension des attaques

6. Exploration d'Articles Scientifiques

Lecture et analyse de l'article "Machine Learning for Cybersecurity Applications" de la West Virginia University (WVU)

- Synthèse des méthodes et résultats principaux

Étude de "A Comprehensive Review of Anomaly Detection in Web Logs" du Hasso Plattner Institute (HPI)

- Principales techniques d'anomaly detection discutées

Analyse de l'article "CRISIS2020_EasyChair_PID_011"

- Points clés et implications pour la cybersécurité

Exploration de "Conf_SIN2022__SWAF" pour le développement d'un pare-feu applicatif basé sur du machine learning

- Innovations et applications potentielles

7. Modélisation et Évaluation des Modèles

Modélisation des URL : KNN, SVM, regression logistique, CNN

Utilisation de ChatGPT et des GPU pour accélérer le développement

Organisation des priorités et gestion des expérimentations

8. Travail avec Splunk et Pipelines

Traitement des données Splunk en préproduction

Tokenization des URL et limitations

Développement de pipelines et utilisation de GridsearchCV

Évaluation des performances des modèles

9. Expérimentations et Déploiement

Utilisation de MLFlow pour la gestion des expérimentations

Apprentissage à requêter et déployer un modèle via une API

Déploiement sur un cluster Kubernetes et gestion du preprocessing

Introduction à Metaflow (Netflix) et tests préliminaires

10. Reproductibilité et MLOps

Importance de la reproductibilité et utilisation des cours de l'ENSAE

Réalisation d'un projet MLOps :

- **Déploiement d'une API sur Kubernetes**
- **Système d'entraînement et stockage des modèles**

Exploration de Spark pour le calcul et le streaming

Conclusion

Bilan du stage et accomplissements

Perspectives futures : Améliorations et extensions possibles

Remerciements et réflexions personnelles

Annexe

Ressources supplémentaires : Notebooks, articles, tutoriels, dépôts Github

Détails techniques des implémentations et configurations

Bibliographie et références